

De la trayectoria al cluster: documentación metodológica completa

Sistema de Generación de Perfiles del Personal Docente y Administrativo en ESPOL para la asignación inteligente de tareas

Generado el 2026-09-09 · Cubre el trabajo realizado del 2026-09-07 al 2026-09-08 · Todas las decisiones marcadas **DEC-XXX** están registradas en `context/DECISION_LOG.md`

Cómo leer este documento: está organizado en el mismo orden cronológico en que se tomaron las decisiones, no como una descripción final aislada. Cada fase explica qué se probó, qué herramientas se evaluaron, qué resultado dieron, y por qué se aceptó o descartó cada alternativa — incluyendo los dos rediseños que se descartaron por el camino (DEC-007 y DEC-008), porque también forman parte de por qué el resultado final es el que es.

Índice

1. Punto de partida: qué existía antes de este trabajo
2. Fase 1 — Auditoría de los datos disponibles
3. Fase 2 — Construcción de la taxonomía de rol (`CATEGORIA_CARGO`)
4. Fase 3 — Trayectorias: tramos de rol, transiciones y features (`04_trayectorias`)
5. Fase 4 — Bug de vigencia encontrado y corregido (DEC-005)
6. Fase 5 — Reordenamiento de notebooks (DEC-006)
7. Fase 6 — Preparación de la matriz de modelado (`05_preparacion_modelado`)
8. Fase 7 — Selección del algoritmo de clustering: qué se evaluó y por qué
9. Fase 8 — Primer reclustering con trayectoria (DEC-007)
10. Fase 9 — Primer intento de jerarquía AA/DD con K-Means (DEC-008) — y por qué se descartó
11. Fase 10 — Diseño final: jerarquía por cargo real + mapa de afinidad (DEC-009)
12. Resultado final: los 13 grupos
13. El dendrograma: qué tan cerca están los grupos entre sí
14. El dashboard: cómo se usa todo esto
15. Mapa completo de archivos del proyecto
16. Limitaciones conocidas y pendientes
17. Glosario

1. Punto de partida: qué existía antes de este trabajo

Antes de esta fase, la tesis ya tenía un pipeline completo y funcional (Fases 1-4 de la metodología original): extracción e integración de datos institucionales, construcción de features, y un **clustering estático** (K-Means, K=5) sobre el personal, con un dashboard en Streamlit ya construido y una presentación ya realizada. Ese trabajo está documentado en `context/DECISION_LOG.md` como DEC-001 (clustering), DEC-002 (embeddings de texto) y DEC-003 (arquitectura del dashboard).

El punto de partida de este documento es una decisión explícita del usuario: **el análisis de trayectorias (cómo evoluciona una persona en el tiempo, no solo su estado actual) pasa a ser el eje central del análisis**, en vez de un complemento del clustering estático. Esto llevó a reconstruir buena parte del pipeline de modelado, como se documenta a continuación.

2. Fase 1 — Auditoría de los datos disponibles

Antes de escribir código, se revisaron todas las tablas de `data/processed/` para determinar cuáles tenían granularidad temporal real (una fila por evento/período, no un acumulado por persona) y cuáles no. Este paso es importante porque construir un modelo de trayectorias sobre datos que ya vienen agregados por persona (sin fecha) sería imposible.

Archivo	Granularidad encontrada	Uso
<code>historial_laboral_personas.csv</code>	Un registro por contrato individual , con fechas exactas de inicio/fin y <code>CARGO</code> textual	Base de toda la taxonomía de rol y las trayectorias
<code>historial_laboral_periodos_continuos.csv</code>	Contratos ya fusionados en períodos continuos de vinculación	Ya existía; se reutilizó la lógica de continuidad (<code>_continuacion_por_corte_de_mes</code>) para los tramos de rol
<code>carga_academica_disponible.csv</code>	Una fila por materia × período académico (año + término 1S/2S)	Confirmado apto para una futura capa de EVENTOS (no se usó aún en el modelo final)
<code>carga_politecnica_disponible.csv</code>	Una fila por actividad × año	Ídem
<code>capacitaciones_todas.csv</code> , <code>publicaciones.csv</code> , <code>proyectos_investigacion_disponible.csv</code> , etc.	Fecha o año de evento individual	Confirmadas aptas para EVENTOS; siguen usándose como agregados por persona en <code>dataset_personas_features.csv</code> (fase anterior)
<code>historial_laboral_features.csv</code> , <code>dataset_personas_integrado.csv</code>	Ya agregadas por persona (una fila = una persona, sin fecha)	Confirmado que la dimensión temporal se había perdido al construir estos archivos — motivó reconstruirla desde <code>historial_laboral_personas.csv</code>

Conclusión de esta fase: `historial_laboral_personas.csv` (73,915 contratos de 3,951 personas) es la única fuente con el detalle necesario para reconstruir trayectorias reales, y se decidió partir de ahí.

3. Fase 2 — Construcción de la taxonomía de rol (CATEGORIA_CARGO)

El campo `CARGO` de `historial_laboral_personas.csv` es texto libre con **1,134 valores distintos** — demasiado granular para analizar directamente, y con ruido de codificación (caracteres acentuados perdidos de forma irrecuperable en el origen). Se construyó una taxonomía intermedia entre `TIPOEMPLEADO` (AA/DD, ya dado) y el `CARGO` textual, mediante reglas de texto (expresiones regulares) validadas contra los datos reales, **nunca inventadas a priori**.

3.1 Decisiones de negocio tomadas durante esta construcción

Problema encontrado	Decisión tomada	Evidencia
Las reglas de texto se evaluaban sobre todo el dataset junto, y "DIRECTOR" contenía "RECTOR" como subcadena	Reglas separadas por rama (AA nunca comparte reglas con DD) y ancladas con inicio de cadena (^)	909 filas administrativas se corrigieron de estar mal clasificadas como autoridad académica
Nomenclatura legado pre-reforma LOES ("Profesor Agregado/Auxiliar/Principal", sin la palabra "Titular")	Fusionar con <code>DOCENTE_TITULAR_CARRERA</code>	95-100% de las personas con esos cargos aparecen después con el cargo "Titular" equivalente (verificado por continuidad de persona)
Rótulos legado ambiguos ("Profesor Pregrado", "Profesor", "Docente", todos ≤2014)	Resolver por continuidad de persona: si después tuvo un cargo Titular → Titular; si no → No Titular Ocasional (decisión confirmada por el usuario)	2,281 filas → Titular; 1,267 filas → No Titular Ocasional
563 registros (1.5% de administrativos) con <code>CARGO</code> tipo "Profesor.../Docente..." pero <code>TIPOEMPLEADO=Administrativo</code>	Tratar como ruido de captura de datos (confirmado por el usuario), no como señal de trayectoria — se excluyen del análisis de transiciones	Marca <code>ES_RUIDO_CALIDAD_DATOS=True</code>
Categorías de contrato puntual/por proyecto (servicios profesionales, contratos civiles, tribunal, honorario) coexistían con el cargo estructural continuo de una persona	Excluir del ESTADO de rol (no generan "transición"); quedan como insumo de una futura capa de <code>EVENTOS</code>	Sin este filtro, una persona llegó a mostrar 103 "transiciones" con brechas negativas (evidencia de contratos paralelos, no de cambios secuenciales)

3.2 Resultado: 24 categorías (11 en Docente, 13 en Administrativo)

Cobertura final: 99.8% de las filas de Docente y 98.8% de Administrativo quedaron clasificadas con confianza (el resto, `SIN_DATO` o `OTROS`, se dejó explícito en vez de forzarlo).

4. Fase 3 — Trayectorias: tramos de rol, transiciones y features

(04_trayectorias.ipynb)

Con CATEGORIA_CARGO ya calculada, se construyeron tres capas nuevas, implementadas como funciones reutilizables en notebooks/01_preprocesamiento/_preprocesamiento_comun.py:

- **construir_tramos_rol**: colapsa contratos consecutivos de la misma categoría en "tramos" (igual lógica de continuidad que los períodos laborales), excluyendo las categorías puntuales y el ruido de datos.
- **detectar_transiciones_rol**: registra cada cambio de categoría entre tramos consecutivos de una persona, con el tipo de transición (AA→AA, AA→DD, DD→AA, DD→DD) y el intervalo entre ambos.
- **construir_features_trayectoria**: agrega todo lo anterior a una fila por persona — número de tramos, categorías distintas, categoría actual, categoría de entrada, antigüedad en la categoría actual, número de transiciones (total y por tipo), y años desde la última transición.

Resultado: **13,556 tramos de rol** y **4,468 transiciones** detectadas sobre 2,983 personas con historial laboral (de 3,951 totales). Se documentó una limitación conocida sin resolver: un patrón de "**encargos cortos**" (nombramientos de autoridad de pocos días, repetidos) sigue generando conteos altos de transición para un puñado de personas — no es ruido de datos, pero requeriría una regla adicional (p. ej. duración mínima de tramo) que no se definió con el usuario.

5. Fase 4 — Bug de vigencia encontrado y corregido DEC-005

Causa raíz: el código original calculaba "vigente" como "el contrato no tiene fecha de fin registrada". Pero de 73,915 contratos, solo el 1.9% tiene esa fecha vacía — RRHH graba casi siempre una fecha fin *planificada* (fin de periodo académico o fiscal) incluso en contratos activos. Con esa lógica, el **81% de las 643 personas cuyo último contrato estaba activo** quedaban marcadas incorrectamente como no vigentes (algunas incluso con fecha de fin todavía en el futuro).

Corrección: nueva función calcular_fecha_fin_efectiva que usa ESTADOCONTRATO (ACTIVO/POR EJECUTARSE = contrato abierto) como señal autoritativa, sin importar si hay una fecha de fin planificada. Verificado: 643/643 quedan correctamente vigentes tras el fix.

Propagación: el fix se propagó por *toda* la cadena de notebooks (01→02→03→04→05→06→08) — la vigencia institucional pasó de **30.9%** (con el bug) a **57.7%** (corregida). Este fue el hallazgo que motivó re-ejecutar el pipeline completo varias veces durante este trabajo.

6. Fase 5 — Reordenamiento de notebooks DEC-006

Como las features de trayectoria debían alimentar el clustering (no quedar como análisis aparte posterior), se reordenaron las carpetas de notebooks/ para que la ejecución en orden numérico refleje esa dependencia:

Orden	Carpeta	Contenido
1	01_preprocesamiento/	18 notebooks de limpieza de cada fuente cruda (antes sin numerar como fase)

2	02_integracion_datos/	Une todas las fuentes procesadas por IDPERSONA
3	03_construccion_features/	Construye <code>dataset_personas_features.csv</code> (85 variables)
4	04_trayectorias/	Nuevo. Antes era 08_trayectorias (al final); ahora antecede al modelado
5	05_preparacion_modelado/	Imputación, transformación, codificación, escalamiento → <code>X_modelado.csv</code>
6	06_clustering/	Selección de algoritmo y modelo final
7	07_embeddings/	Representación semántica de texto (sin cambios en este trabajo)
8	08_dashboard/	Preparación de datos + app Streamlit

7. Fase 6 — Preparación de la matriz de modelado (05_preparacion_modelado)

Este notebook transforma las variables "naturales" en una matriz numérica apta para K-Means. Se agregó una sección nueva para fusionar las features de trayectoria (Fase 3) antes de la clasificación de variables, siguiendo el mismo estándar de rigor que ya tenía el notebook (cada decisión de imputación documentada y justificada, nunca "NaN → 0" de forma genérica).

7.1 Clasificación de variables y su tratamiento

Tipo	Cantidad final	Tratamiento
Numéricas	79	<code>log1p</code> si <code> skew ≥ 2</code> y no es una tasa/proporción (para no comprimir escalas ya acotadas 0-1), luego <code>StandardScaler</code>
Ordinal	1 (NIVEL_ACADEMICO_MAXIMO)	Orden semántico explícito (sin_registro<primaria<bachillerato<tercer_nivel<cuarto), luego <code>StandardScaler</code>
Categorías nominales	54 columnas dummy (de un puñado de variables originales, incl. las 2 nuevas de trayectoria: categoría de cargo actual/primera)	<code>OneHotEncoder</code> , con "DESCONOCIDO" como categoría explícita para nulos
Binarias	7 (incl. 3 nuevas de trayectoria: estabilidad, tuvo transición AA→DD/DD→AA)	Passthrough 0/1, sin re-escalar
Excluidas por alta cardinalidad	3 (CARGO_ACTUAL, CARGO_MAS_FRECUENTE, UNIDAD_ACTUAL_NOMBRE)	>20 categorías; quedan documentadas pero fuera de <code>X_modelado</code>

Resultado: `X_modelado.csv` pasó de **100 a 141 columnas** (2,213 personas × 141 variables), sin nulos ni infinitos.

7.2 StandardScaler vs. RobustScaler: por qué se eligió StandardScaler

Se compararon ambos escaladores sobre los datos ya imputados y transformados. `RobustScaler` divide por el rango intercuartílico (IQR); tras aplicar `log1p`, ~27% de las columnas quedaron con **IQR=0** (variables muy concentradas en cero), lo que deja esas columnas sin normalizar y produce valores muy fuera de rango (hasta ~45 vs ~1-9 en el resto). `StandardScaler` no tiene ese problema colateral, así que se usó como escalador final.

8. Fase 7 — Selección del algoritmo de clustering: qué se evaluó y por qué

Esta evaluación (hecha sobre la población completa antes de introducir la jerarquía AA/DD) es la base metodológica que se reutilizó después para las fases 8-10. Se probaron 3 familias de algoritmos:

8.1 K-Means (K=2 a K=12)

K	Silhouette	Calinski-Harabasz	Davies-Bouldin	Tamaño min-max
2	0.249	608.5	1.83	717 – 1,496
3	0.126	429.4	2.07	591 – 926
4	0.125	363.4	2.22	351 – 720
5	0.125	309.1	2.24	209 – 644
6	0.121	272.2	2.34	173 – 571
7	0.115	245.1	2.25	168 – 546
8-12	0.08-0.11	163-221	2.29-2.53	cae a grupos de 15-119

El Silhouette es máximo en K=2 y decrece monótonamente — pero K=2 **no separa limpiamente docente de administrativo** (se verificó cruzando la partición K=2 contra TIPOEMPLEADO_ACTUAL_DESC): el corte principal responde solo al volumen general de actividad/antigüedad, no a un patrón sustantivo. Por eso no se elige K únicamente por el mejor Silhouette.

Estabilidad (Adjusted Rand Index entre 5-8 semillas distintas por K): K=5 fue consistentemente el punto más estable (ARI≈0.97-0.99), muy por encima de K≥8 (donde cae a 0.7-0.86) — es decir, la estructura de los datos deja de sostener con claridad más de ~7 grupos.

8.2 Clustering jerárquico (Agglomerative, enlace ward)

Se probó como validación cruzada, no como candidato independiente: para todos los K evaluados, K-Means igualó o superó a Agglomerative en las 3 métricas de calidad. El ARI entre ambas soluciones para el mismo K se mantuvo entre 0.56 y 0.66 (bajó tras agregar las features de trayectoria) — acuerdo sustancial pero no idéntico, suficiente para dar confianza de que la estructura no es un artefacto de un solo algoritmo.

8.3 DBSCAN y HDBSCAN — descartados

DBSCAN (eps=3 a 10, min_samples=5/10): con eps bajo (3-4), entre 83% y 93% de las personas quedan como *ruido*, formando solo 2-10 clusters diminutos. Al subir eps a 8-10 para bajar el ruido (1.8%-18.3%), el algoritmo colapsa a 1-2 clusters gigantes. No hay un rango intermedio con varios clusters sustanciales y poco ruido.

HDBSCAN (min_cluster_size=20 a 100): con 20 encuentra 2 clusters dejando 90.5% como ruido; con 30 o más, **no encuentra ningún cluster** (100% ruido).

Conclusión: comportamiento esperado en una matriz de 141 dimensiones con variables dummy dispersas — no existe una noción de densidad bien diferenciada. Se descartan ambos métodos para la solución final; no se fuerza su uso solo por ser "más sofisticados".

8.4 PCA — solo para visualización, nunca para clustering

Se usó PCA a 2 componentes exclusivamente para poder graficar los clusters en un plano. La varianza explicada por esas 2 componentes es baja (esperable en 141 dimensiones) — se documentó explícitamente que es una ayuda visual y no resume fielmente la matriz completa usada para clusterizar.

9. Fase 8 — Primer reclustering con trayectoria DEC-007

Con el bug de vigencia corregido y las features de trayectoria ya fusionadas a `X_modelado.csv` (100→141 columnas), se repitió toda la evaluación de la Fase 7. **K=5 se mantuvo** como la mejor solución bajo los mismos criterios (seguía siendo el K más estable, $ARI \approx 0.97$), pero la composición de personas cambió y, con ella, la interpretación:

- Apareció un perfil con **76.1% de transiciones administrativo→docente** y **63.2% docente→administrativo** (vs. 16.8%/10.0% institucional), con mediana de 5 transiciones y la mayor antigüedad de toda la población (25.5 años) — el patrón de movilidad de rol que había motivado agregar trayectoria como feature.
- El acuerdo con el clustering jerárquico bajó de ~0.66 a ~0.56 — señal de que las nuevas features (movilidad) introducen una estructura que ambos algoritmos capturan de forma algo más distinta entre sí, sin dejar de coincidir en lo esencial.

Esta solución (K=5, un único clustering global) se registró como **DEC-007**, reemplazando a DEC-001. Pero fue superada el mismo día por las fases 9 y 10, a partir de nuevos requerimientos del usuario.

10. Fase 9 — Primer intento de jerarquía AA/DD con K-Means DEC-008 — descartado

El usuario pidió una visualización de puntos individuales (clicables, identificando a la persona), coloreada por grupo, con los **dos grupos principales siendo Administrativo y Docente**, y filtros por tipo de empleado. Primer diseño (DEC-008): mantener `TIPOEMPLEADO_ACTUAL_DESC` como nivel 1, y correr **K-Means por separado dentro de cada rama** para hallar sub-perfiles propios.

Rama	K elegido	Estabilidad (ARI)	Tamaños
Administrativo (n=693)	4	0.98	37 – 333
Docente (n=1,515)	5	0.98	161 – 493

Resultado: 9 sub-perfiles, incluyendo uno llamado *"Administrativo con alta movilidad hacia docencia"* y otro *"Docente con alta movilidad de rol"* — cada uno definido por tener valores altos en variables de movilidad (número de transiciones, diversidad de cargos).

Por qué se descartó (corrección del usuario): convertir la movilidad de rol en una *categoría de cluster* era conceptualmente incorrecto. Esa señal ya vive en las variables (`N_TRANSICIONES_ROL`, `TUVO_TRANSICION_AA_A_DD`, etc.); forzarla a ser una etiqueta de grupo aparte contradice el principio del propio proyecto de que los perfiles son una representación analítica complementaria, no una reclasificación de la persona. Un docente cuya trayectoria se parece a la de un subdecano debe seguir etiquetado como lo que realmente es — la similitud debe verse como **cercanía en un mapa**, no como una nueva categoría inventada por el algoritmo.

11. Fase 10 — Diseño final: jerarquía por cargo real + mapa de afinidad

DEC-009

Se reemplazó el nivel 2 de K-Means por una **asignación directa basada en reglas**, usando la taxonomía `CATEGORIA_CARGO_ACTUAL` ya construida y validada en la Fase 2/3 — sin volver a clusterizar nada. No hay K que elegir ni estabilidad que evaluar en este paso: es una traducción categoría→grupo ya acordada con el usuario.

- **Nivel 1** (dato institucional, no descubierto): `TIPOEMPLEADO_ACTUAL_DESC` — Administrativo o Docente. Se confirmó con el usuario que Rector/Vicerrector/Decano/Subdecano se mantienen bajo **Docente**, tal como los codifica ESPOL (se eligen desde el escalafón docente), aunque ejerzan una función directiva.
- **Nivel 2** (regla ya validada, DEC-004): `CATEGORIA_CARGO_ACTUAL` — 13 categorías con al menos 1 persona en esta población.
- **El mapa de puntos (PCA)** pasa a ser explícitamente la herramienta de *afinidad de trayectoria*: todas las personas comparten el mismo espacio 2D, así que alguien puede aparecer visualmente cerca de un grupo distinto al suyo si su trayectoria se le parece, sin que eso cambie su categoría real ni se convierta en una predicción.

Limitación conocida (sin resolver): `TIPOEMPLEADO_ACTUAL_DESC` (de `historial_laboral_features`, último contrato) y `CATEGORIA_CARGO_ACTUAL` (de `tramos_rol`, tramo vigente no puntual) se calculan con lógicas de "actual" ligeramente distintas y no siempre coinciden en la rama esperada. El caso más notable: **74 personas** con `TIPOEMPLEADO=Administrativo` cuya categoría de cargo vigente es "Técnico docente". No se forzó a coincidir; queda documentado para una futura revisión de consistencia entre ambas fuentes.

12. Resultado final: los 13 grupos

Sobre 2,208 personas con categoría de cargo asignada (de 2,213; 5 personas sin historial laboral quedan sin grupo, ver sección 16).

#	Grupo (categoría de cargo real)	Rama predominante	Personas	% población
11	Técnico docente / de investigación	Docente	755	34.1%
4	Docente no titular / ocasional	Docente	547	24.7%
8	Profesional / Analista	Administrativo	294	13.3%
5	Docente titular de carrera	Docente	268	12.1%
0	Asistencia secretarial / oficina	Administrativo	173	7.8%
1	Autoridad académica (Rector/Vicerrector/Decano/Subdecano)	Docente	34	1.5%
3	Auxiliar / ayudante operativo	Administrativo	30	1.4%
9	Profesional especializado (abogado, psicólogo, etc.)	Administrativo	30	1.4%
2	Autoridad administrativa (Gerente/Director)	Administrativo	29	1.3%
10	Servicios generales / oficios	Administrativo	17	0.8%

6	Jefatura / supervisión operativa	Administrativo	15	0.7%
12	Técnico operativo / mantenimiento	Administrativo	11	0.5%
7	Otros (administrativo)	Administrativo	5	0.2%

Nota: "Rama predominante" es la TIPOEMPLEADO_ACTUAL_DESC más frecuente dentro del grupo; algunos grupos tienen un pequeño número de personas de la otra rama (ver limitación de la sección 11).

13. El dendrograma: qué tan cerca están los grupos entre sí

Se construyó un dendrograma (enlace ward) sobre el centroide de cada uno de los 13 grupos, en el mismo espacio de 141 variables usado para el modelo – no sobre personas individuales, y sin influir en la asignación de cada persona a su grupo. Hallazgos destacados:

- Los dos grupos más "senior" – **Autoridad académica** y **Docente titular de carrera** – se separan del resto de la población como una rama propia, distinta de todos los demás grupos combinados. Tiene sentido: comparten antigüedad larga y alta estabilidad institucional.
- **Profesional/Analista** y **Profesional especializado** son los dos grupos más parecidos entre sí de toda la población (la primera fusión del árbol) – coherente, ambos son roles profesionales de oficina.
- **Servicios generales/oficios** y **Técnico operativo/mantenimiento** también se agrupan tempranamente – ambos son roles operativos/manuales.
- **Docente no titular/ocasional** y **Técnico docente/investigación** (los dos grupos docentes más numerosos) se fusionan entre sí antes de unirse al resto – comparten un perfil de actividad docente sin la carrera formal de titular.

Este dendrograma está disponible en el dashboard (pestaña "Resumen general") y los datos crudos en `data/clustering/dendrograma_centroides.csv`.

14. El dashboard: cómo se usa todo esto

La aplicación Streamlit (notebooks/08_dashboard/app.py) tiene 6 pestañas:

Pestaña	Qué muestra
Resumen general	Tamaño de cada grupo, composición por tipo de empleado, y el dendrograma de cercanía entre grupos
Mapa de perfiles	Un punto por persona (proyección PCA), coloreado por categoría de cargo real, con clic para identificar a la persona y filtro por tipo de empleado / categoría – la herramienta de exploración de <i>afinidad de trayectoria</i>
Explorar perfiles	Ficha de cada uno de los 13 grupos: descripción, variables más distintivas, muestra de personas
Buscar persona	Ficha individual por IDPERSONA
Formar equipos / comisiones	Filtros combinados (perfil, vigencia, tipo, nivel académico, publicaciones, experiencia) para armar listas de candidatos
Búsqueda semántica	Búsqueda por texto libre sobre los embeddings de la Fase de embeddings (sin cambios en este trabajo)

Para correrlo: `d:\Proyecto_Tesis\.venv\Scripts\streamlit run notebooks\08_dashboard\app.py` (entorno virtual separado del resto de los notebooks – ver sección 15).

15. Mapa completo de archivos del proyecto

15.1 Notebooks (orden de ejecución)

Notebook	Lee	Produce
01_preprocesamiento/*.ipynb (18)	data/raw/*.csv	data/processed/*.csv, incl. historial_laboral_personas.csv, historial_laboral_features.csv
01_preprocesamiento/_preprocesamiento_comun.py		Funciones compartidas: calcular_fecha_fin_efectiva, clasificar_categoria_cargo, construir_tramos_rol, detectar_transiciones_rol, construir_features_trayectoria, extraer_eventos_puntuales
02_integracion_datos.ipynb	data/processed/*.csv	data/features/dataset_personas_integrado (2, 213×96)
03_construccion_features.ipynb	dataset_personas_integrado.csv	data/features/dataset_personas_features. (2, 213×86), feature_dictionary.csv, features_excluded.csv
04_trayectorias.ipynb	data/processed/historial_laboral	data/trayectorias/historial_laboral_cate tramos_rol.csv, transiciones_rol.csv, eventos_puntuales_cargo.csv, features_trayectoria_persona.csv
05_preparacion_modelado.ipynb	dataset_personas_features.csv + features_trayectoria_persona.csv	data/modeling/X_modelado.csv (2, 213×141), personas_modelado.csv, feature_names_modelado.csv, preprocessing_summary.csv, preprocessor.joblib
06_clustering.ipynb	X_modelado.csv	data/clustering/: clusters_personas.csv, cluster_sizes.csv, cluster_profiles.csv, cluster_characterization.csv, pca_personas.csv, dendrograma_centroides.csv, evaluacion_k*.csv, modelo_clustering.joblib
07_embeddings.ipynb	dataset_personas_features.csv (texto)	data/embeddings/*.csv (sin cambios en este trabajo)

08_dashboard.ipynb	data/clustering/ + data/features/ + data/embeddings/	data/dashboard/personas_dashboard.csv, cluster_perfiles_resumen.csv, cluster_top_features.csv
08_dashboard/lib.py	–	Nombres/descripciones/colores de los 13 grupos (PERFIL_NOMBRES, PERFIL_DESCRIPCIONES, PERFIL_COLORES), funciones de carga de datos
08_dashboard/app.py	data/dashboard/, data/clustering/pca_personas.csv	Aplicación Streamlit (6 pestañas, ver sección 14)

15.2 Entornos de ejecución

Entorno	Usado por	Por qué
Intérprete global (Python311, kernel proyecto-tesis-py311)	Notebooks 01 a 07	Entorno compartido con otras herramientas de la máquina
.venv/ del proyecto (kernel proyecto-tesis-dashboard)	Notebook 08 y app.py	Streamlit/Plotly generaban conflicto de dependencias (starlette) con el entorno global – aislado para no romper otras herramientas (DEC-003)

15.3 Decisiones registradas en context/DECISION_LOG.md

ID	Título	Estado
DEC-001 a DEC-003	Clustering estático original (K=5), embeddings, arquitectura del dashboard	DEC-001 reemplazada por DEC-007; DEC-002/003 vigentes
DEC-004	Pivote a trayectorias + taxonomía CATEGORIA_CARGO	Vigente
DEC-005	Corrección del bug de vigencia	Vigente
DEC-006	Reordenamiento de notebooks	Vigente
DEC-007	Reclustering K=5 global con trayectoria	Reemplazada por DEC-008
DEC-008	Clustering en 2 niveles con K-Means por rama	Reemplazada por DEC-009

DEC-009	Jerarquía por cargo real + mapa de afinidad	Vigente – estructura final
---------	--	-----------------------------------

16. Limitaciones conocidas y pendientes

Población base desactualizada (sin resolver). El archivo institucional `data/raw/datos_personales_ultimos_5anios.csv` (2,213 personas, base de todo el pipeline) parece un extracto que no se ha refrescado: 1,743 personas con historial laboral real no están incluidas ahí, de las cuales **554 están actualmente vigentes**. Se descubrió porque el propio usuario (`IDPERSONA 655517`, con contrato activo desde 2023) no aparecía en el dashboard. Pendiente de decisión: ampliar la población, dejarlo documentado, o pedir un extracto institucional actualizado.

Patrón de "encargos cortos" sin resolver (DEC-004). Nombramientos de autoridad de pocos días, repetidos, siguen generando conteos de transición altos para un puñado de personas – no es ruido, pero requeriría una regla de duración mínima de tramo no definida aún con el usuario.

Discrepancia `TIPOEMPLEADO_ACTUAL_DESC` vs. `CATEGORIA_CARGO_ACTUAL` (DEC-009). 74 personas administrativas tienen como categoría de cargo vigente "Técnico docente" – ambas columnas se calculan con lógicas de "actual" ligeramente distintas dentro del historial laboral, sin reconciliar todavía.

Escalamiento no reajustado por rama (heredada de DEC-008). El `StandardScaler` de la matriz de modelado se ajustó sobre toda la población conjunta, no por separado – no se evaluó el impacto de reajustarlo.

`07_embeddings.ipynb` no re-ejecutado. Su comparación contra clusters estructurales sigue calculada contra la solución de DEC-001 (ya obsoleta).

Naturaleza mixta de `X_modelado`. Mezcla variables numéricas estandarizadas con variables dummy 0/1 sin estandarizar, lo que pondera más las numéricas en la distancia euclídea de K-Means – documentado desde la Fase 6, no resuelto (sería un cambio de representación mayor).

17. Glosario

Término	Significado en este proyecto
ARI (Adjusted Rand Index)	Mide qué tan parecidas son dos particiones (p. ej. clustering con dos semillas distintas). 1 = idénticas; cerca de 0 = tan parecidas como al azar.
Silhouette / Calinski-Harabasz / Davies-Bouldin	Métricas de calidad de un clustering sin necesitar "respuesta correcta": qué tan compactos y separados quedan los grupos.
Ward (enlace)	Criterio de fusión en clustering jerárquico que minimiza el aumento de varianza dentro de los grupos al unirlos – el más comparable a K-Means.
PCA	Reduce muchas variables a 2 para poder graficar; pierde información, se usa solo como ayuda visual.
Tramo de rol	Período continuo en que una persona mantuvo la misma CATEGORIA_CARGO (fase 3).
Transición de rol	Cambio de CATEGORIA_CARGO entre dos tramos consecutivos de una misma persona.
Categoría puntual	Categoría de cargo que representa un contrato por proyecto/servicio civil, que puede coexistir con el cargo estructural de una persona (no genera "transición").
Afinidad de trayectoria	Cercanía visual en el mapa PCA entre una persona y un grupo distinto al suyo – una señal para explorar, nunca una reclasificación ni una predicción.

Documento generado a partir del historial de trabajo de esta sesión (2026-09-07 a 2026-09-08) sobre el repositorio d:\Proyecto_Tesis. Todas las cifras provienen de una re-ejecución verificada de los notebooks mencionados.